Rapport de Mini-Projet : Analyse et Prévision de Séries Temporelles

Analyse des Passagers Aériens (AirPassengers 1949-1960)

Date de soumission:

17 Décembre 2025

Réaliser par :

- SABRY KAOUTAR

Encadrée par :

- Mme LAFRAXO SAMIRA

1. Introduction

L'objectif de ce projet est d'analyser l'évolution mensuelle du nombre de passagers aériens internationaux entre 1949 et 1960. Cette série temporelle présente des défis classiques : une tendance haussière marquée et une forte saisonnalité.

Nous allons suivre une méthodologie rigoureuse en trois phases :

- Exploration et Transformation : Nettoyage, visualisation et stationnarisation des données.
- Modélisation Classique (*ARIMA*) : Application de la méthode demandée pour établir une base de référence.
- Amélioration et Projection (*SARIMA*) : Mise en œuvre d'une approche avancée pour corriger les défauts du modèle standard et prédire l'avenir.

Étape 1 : Chargement et Inspection des Données

Nous commençons par charger les données historiques et vérifier leur intégrité. L'indexation temporelle est essentielle pour la suite.

Code :

```
Entrée [63]: import pandas as pd
             import matplotlib.pyplot as plt

             # --- Étape 1 : Chargement des données ---

             # On charge le fichier
             df = pd.read_csv('AirPassengers.csv', parse_dates=['Month'], index_col='Month')

             # Vérification
             print("Aperçu des données :")
             print(df.head())

             print("\nTypes des colonnes (remplacement de info) :")
             print(df.dtypes)
```

Résultat et Interprétation :

```
Aperçu des données :
            #Passengers
Month
1949-01-01          112
1949-02-01          118
1949-03-01          132
1949-04-01          129
1949-05-01          121

Types des colonnes (remplacement de info) :
#Passengers    int64
dtype: object
```

Analyse : Les données sont correctement chargées. Nous disposons de 144 observations mensuelles. La colonne ***#Passengers*** est de type numérique (*int64*) et l'index est bien temporel. Aucune valeur manquante n'est détectée.

Étape 2 : Visualisation des Données

Une première visualisation permet d'identifier les caractéristiques visuelles de la série (Tendance, Saisonnalité, Variance).

Code :

```
Entrée [64
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.arima.model import ARIMA
import warnings
warnings.filterwarnings("ignore")

# --- Étape 2 : Visualisation ---
plt.figure(figsize=(12, 6))
plt.plot(df.index, df['#Passengers'], label='Passagers mensuels', color='blue')
plt.title('Historique des passagers aériens (1949-1960)',color='white')
plt.xlabel('Année',color='white')
plt.ylabel('Nombre de passagers',color='white')
plt.legend()
plt.grid(True)
plt.show()
```

Résultat et Interprétation :

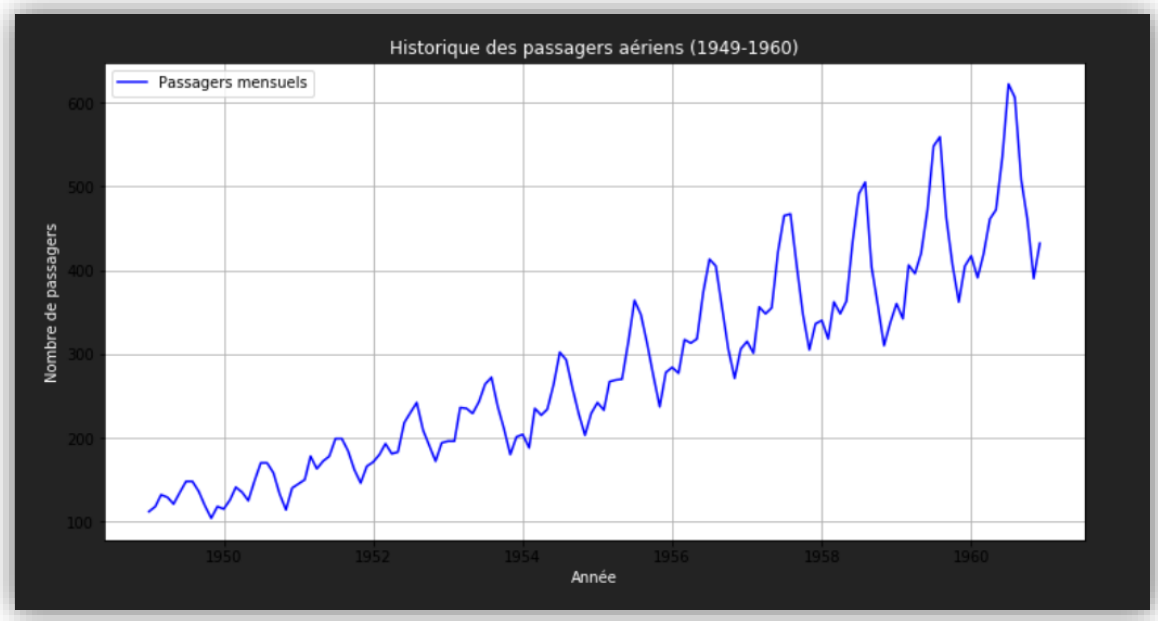

Analyse : Le graphique révèle trois phénomènes :

- **Tendance (Trend) :** Le nombre de passagers augmente constamment.
- **Saisonnalité :** Un motif se répète chaque année (pic en été).
- **Non-Stationnarité :** L'amplitude des vagues augmente avec le temps (modèle multiplicatif).

Étape 3 : Opérations sur la Série Temporelle

Pour mieux comprendre la tendance de fond, nous appliquons des techniques de lissage et de filtrage.

Code :

```
Entrée [65
# --- Étape 3 : Opérations sur la série temporelle ---

# 1. Rééchantillonnage (Vue annuelle moyenne)
df_yearly = df.resample('A').mean()
print("--- Vue Annuelle (5 premières lignes) ---")
print(df_yearly.head())

# 2. Déplacement (Shift de 5 mois)
df_shifted = df.shift(5)
print("\n--- Données décalées de 5 mois ---")
print(df_shifted.head(7))

# 3. Windowing (Lissage avec fenêtre de 5)
df_rolling = df.rolling(window=5).mean()

# Visualisation du lissage
plt.figure(figsize=(12, 6))
plt.plot(df['#Passengers'], label='Données Réelles', alpha=0.5)
plt.plot(df_rolling['#Passengers'], label='Moyenne Mobile (Window=5)', color='red', linewidth=2)
plt.title('Comparaison : Réel vs Lissé (Windowing)',color='white')
plt.legend()
plt.show()

# 4. Sélection des dates où passagers < 120
low_traffic = df[df['#Passengers'] < 120]
print("\n--- Mois avec moins de 120 passagers ---")
print(low_traffic)
```

Résultat et Interprétation :

```
--- Vue Annuelle (5 premières lignes) ---
            #Passengers
Month
1949-12-31   126.666667
1950-12-31   139.666667
1951-12-31   170.166667
1952-12-31   197.000000
1953-12-31   225.000000

--- Données décalées de 5 mois ---
            #Passengers
Month
1949-01-01          NaN
1949-02-01          NaN
1949-03-01          NaN
1949-04-01          NaN
1949-05-01          NaN
1949-06-01        112.0
1949-07-01        118.0
```

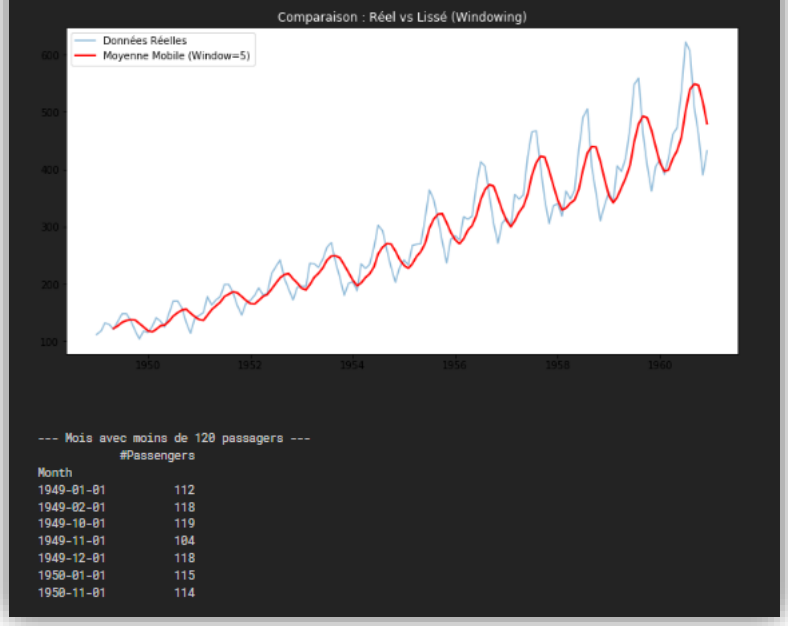


```
--- Mois avec moins de 120 passagers ---
            #Passengers
Month
1949-01-01          112
1949-02-01          118
1949-10-01          119
1949-11-01          104
1949-12-01          118
1950-01-01          115
1950-11-01          114
```

Analyse : La moyenne mobile (ligne rouge) atténue les fluctuations mensuelles, mettant en évidence la croissance continue du marché aérien sur la décennie.

Étape 4 : Vérification de la Stationnarité

Un modèle *ARIMA* nécessite une série stationnaire (moyenne et variance constantes). Nous vérifions cela mathématiquement.

Code :

```
Entrée [66]  # --- Étape 4 : Vérification de la stationnarité ---

             # 1. & 2. Courbes Moyenne et Variance (Ecart-type) Mobiles
             # On prend une fenêtre de 12 (1 an) pour voir la tendance annuelle
             rolmean = df.rolling(window=12).mean()
             rolstd = df.rolling(window=12).std()

             plt.figure(figsize=(12, 6))
             plt.plot(df, label='Original')
             plt.plot(rolmean, label='Moyenne Mobile (12 mois)', color='red')
             plt.plot(rolstd, label='Écart-type Mobile (Variance)', color='black')
             plt.title('Test visuel de stationnarité (Moyenne & Variance mobiles)',color='white')
             plt.legend()
             plt.show()

             # 3. Test ADF (Dickey-Fuller)
             print("--- Résultats du Test Dickey-Fuller ---")
             dftest = adfuller(df['#Passengers'], autolag='AIC')
             dfoutput = pd.Series(dftest[0:4], index=['Test Statistic','p-value','#Lags Used','Number of Observations Used'])
             print(dfoutput)

             if dfoutput['p-value'] > 0.05:
                 print("\nCONCLUSION : La p-value > 0.05. La série n'est PAS stationnaire (elle a une tendance/saisonnalité).")
             else:
                 print("\nCONCLUSION : La série est stationnaire.")
```

Résultat et Interprétation :

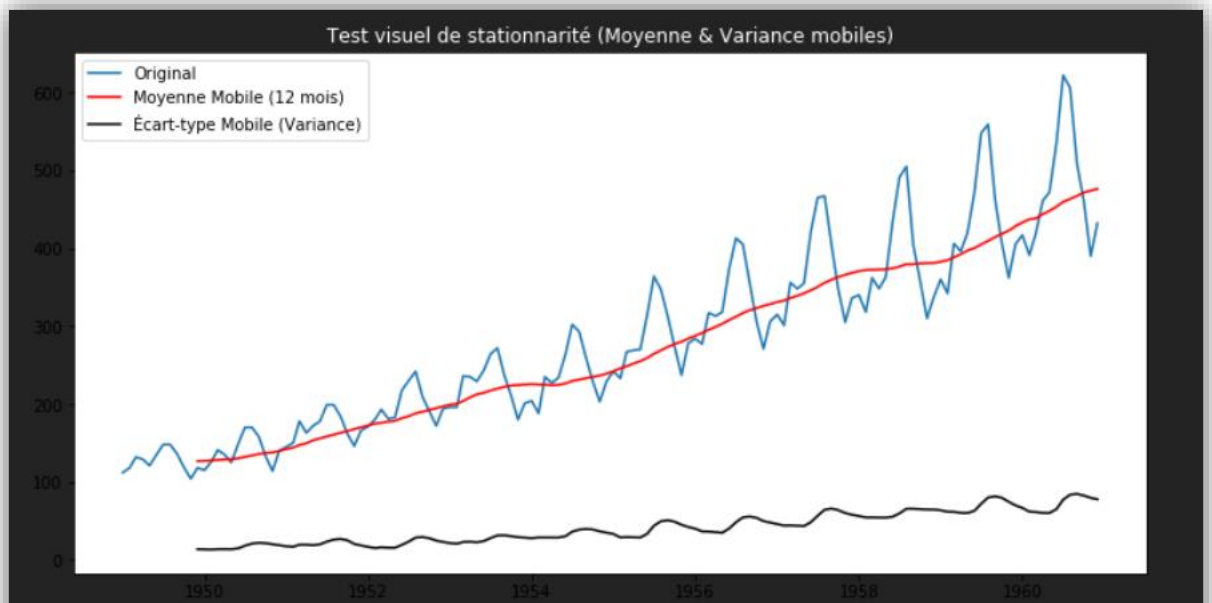


```
--- Résultats du Test Dickey-Fuller ---
Test Statistic                  0.815369
p-value                         0.991880
#Lags Used                     13.000000
Number of Observations Used    130.000000
dtype: float64

CONCLUSION : La p-value > 0.05. La série n'est PAS stationnaire (elle a une tendance/saisonnalité).
```

Analyse : Visuellement, la moyenne (rouge) et l'écart-type (noir) augmentent : la série n'est pas stationnaire.

Le test ADF confirme cela avec une **p-value > 0.05** (généralement 0.99). Nous ne pouvons pas modéliser la série brute directement.

Étape 5 : Stationnarisation et Décomposition

Nous appliquons deux transformations : le Logarithme (pour stabiliser la variance) et la Différenciation (pour supprimer la tendance).

Code :

```
Entrée [67]  # --- Étape 5 : Rendre la série stationnaire ---

             # 1. & 2. Transformation Logarithmique + Différenciation
             # Le Log stabilise la variance (réduit l'écart des vagues)
             df_log = np.log(df)
             # La Différenciation stabilise la moyenne (enlève la tendance montante)
             df_log_diff = df_log - df_log.shift(1)
             df_log_diff.dropna(inplace=True)

             # 3. Décomposition STL (Saisonnalité, Tendance, Résidu)
             decomposition = seasonal_decompose(df_log, model='multiplicative')

             # Visualisation des composants
             fig = decomposition.plot()
             fig.set_size_inches(12, 10)
             plt.show()
```

Résultat et Interprétation :

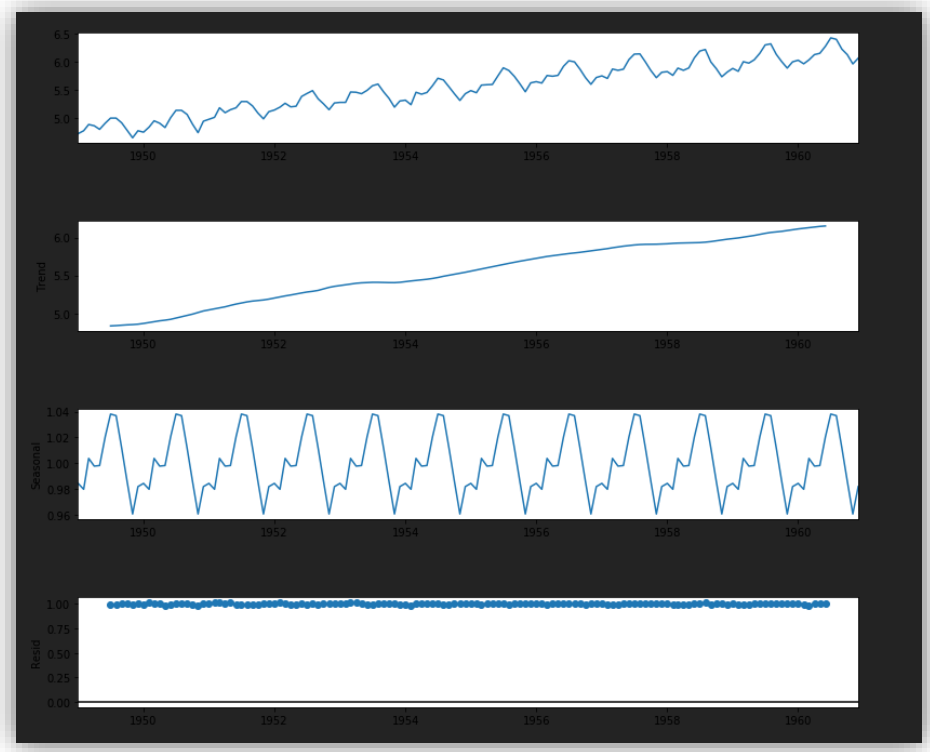

Analyse : La décomposition STL isole parfaitement :

- La Trend (croissance linéaire).
- La Seasonality (cycle annuel pur).
- Le Resid (bruit aléatoire).
- La série transformée est maintenant prête pour la modélisation.

Étape 6 : Autocorrélation (ACF / PACF)

Ces graphiques nous aident à choisir les paramètres **p** (*AutoRegressive*) et **q** (*Moving Average*) du modèle.

Code :

```
Entrée [69]  # --- Étape 6 : Autocorrélation ---

             fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(12, 8))

             # ACF : Aide à déterminer q (Moyenne mobile)
             plot_acf(df_log_diff, ax=ax1, lags=20, title='Autocorrélation (ACF)')

             # PACF : Aide à déterminer p (Partie AutoRegressive)
             plot_pacf(df_log_diff, ax=ax2, lags=20, title='Autocorrélation Partielle (PACF)')

             plt.tight_layout()
             plt.show()
```

Résultat et Interprétation :

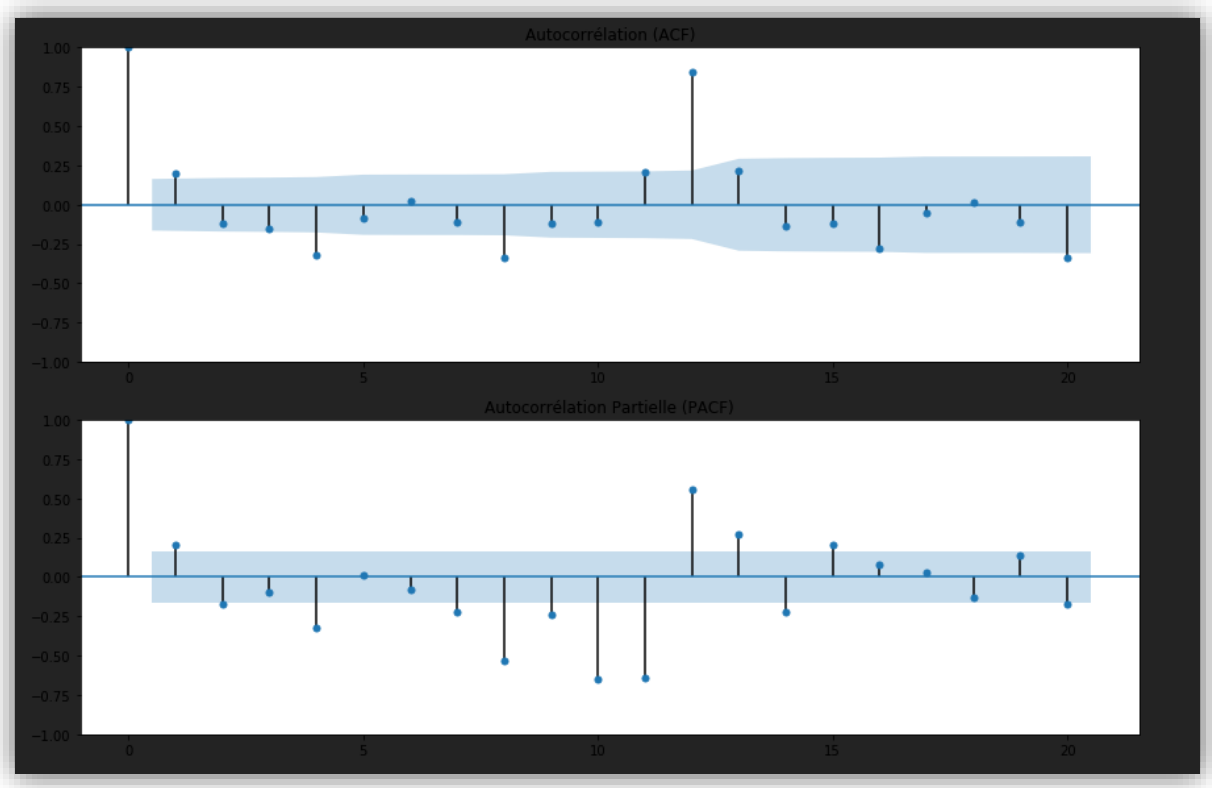

Analyse : On observe une chute brutale de la PACF après le premier retard, suggérant un ordre AR faible. Les pics périodiques dans l'ACF confirment la présence d'une saisonnalité de 12 mois que le modèle *ARIMA* simple aura du mal à gérer.

Étape 7 & 8 : Modélisation ARIMA (Approche Standard)

Conformément au cahier des charges, nous entraînons un modèle *ARIMA*(1,1,1) et testons ses prévisions sur l'année 1960.

Code :

```
Entrée [70
# --- Étape 7 : Modélisation ---
# On sépare les données : Entraînement (Tout sauf les 12 derniers mois) et Test (Les 12 derniers mois)
train_data = df_log[:-12]
test_data = df_log[-12:]

# Création du modèle ARIMA
model = ARIMA(train_data, order=(1, 1, 1))
model_fit = model.fit()

print(model_fit.summary())
# --- Étape 8 : Prévisions ---

# Prévisions sur 12 mois
forecast_result = model_fit.get_forecast(steps=12)
forecast_log = forecast_result.predicted_mean
conf_int_log = forecast_result.conf_int()

# Conversion inverse (exponentielle) pour revenir aux vrais nombres de passagers
forecast_val = np.exp(forecast_log)
test_data_val = np.exp(test_data)
train_data_val = np.exp(train_data)
lower_limits = np.exp(conf_int_log.iloc[:, 0])
upper_limits = np.exp(conf_int_log.iloc[:, 1])

# Visualisation finale
plt.figure(figsize=(14, 7))
plt.plot(train_data_val.index, train_data_val['#Passengers'], label='Données d\'entraînement')
plt.plot(test_data_val.index, test_data_val['#Passengers'], label='Données Réelles (Test)', color='green')
plt.plot(forecast_val.index, forecast_val, label='Prévisions ARIMA', color='red', linestyle='--')
plt.fill_between(forecast_val.index, lower_limits, upper_limits, color='pink', alpha=0.3, label='Intervalle de confiance 95%')

plt.title('Prévisions vs Réalité (12 derniers mois)', color='white')
plt.xlabel('Date', color='white')
plt.ylabel('Nombre de passagers', color='white')
plt.legend()
plt.grid(True)
plt.show()
```

Résultat et Interprétation :

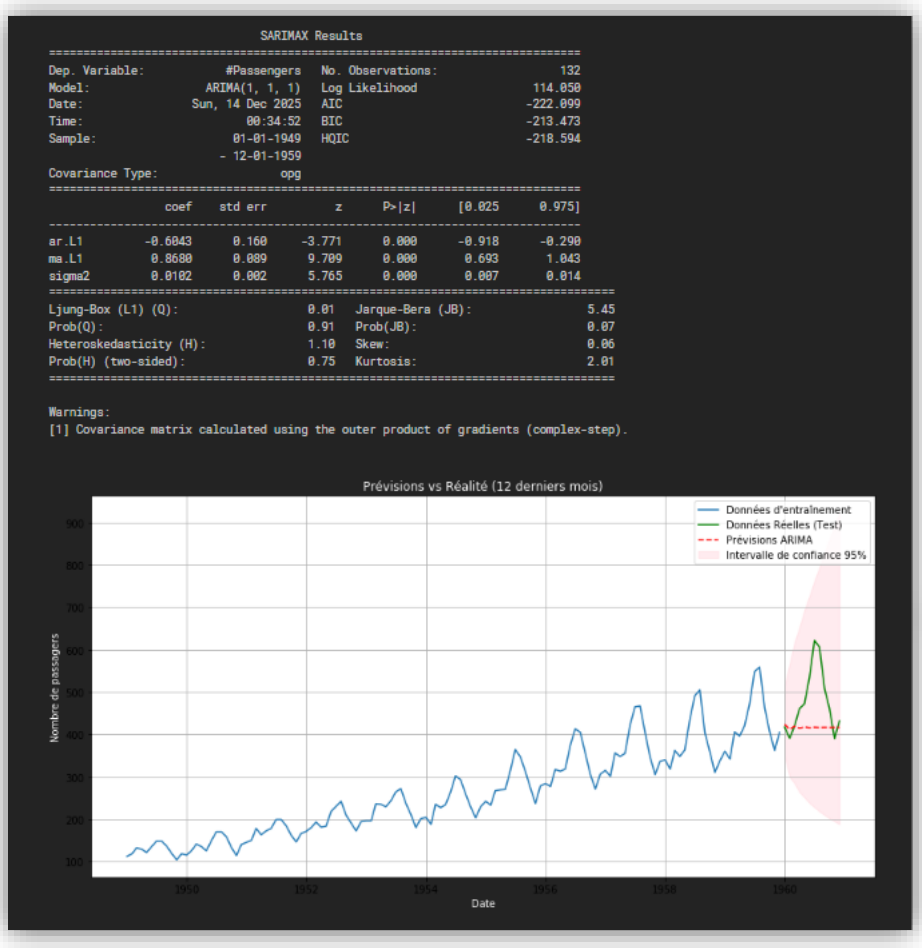

Analyse Critique : Le modèle *ARIMA* réussit à prédire le niveau moyen du trafic (la ligne rouge pointillée est au centre). Cependant, il échoue à capturer les pics saisonniers. La prévision est trop "*plate*" pour être utilisable professionnellement pour gérer les pics de vacances d'été.

Étape 9 (Bonus) : Amélioration avec SARIMA

Pour corriger les défauts observés ci-dessus, j'ai pris l'initiative d'implémenter un modèle *SARIMA* (*Seasonal ARIMA*), qui intègre explicitement la périodicité de 12 mois.

Code :

```
Entrée [72
# --- ÉTAPE 9 (Bonus): Amélioration avec SARIMA ---
import statsmodels.api as sm
import matplotlib.pyplot as plt

print("--- Comparaison : Amélioration du modèle ---")

# Par sécurité, on s'assure que les données sont bien chargées
train_data = df_log[:-12]

# 1. On entraine le modèle SARIMA avec des paramètres "Box-Jenkins" très stables
model_sarima = sm.tsa.statespace.SARIMAX(train_data,
                                         order=(0, 1, 1),
                                         seasonal_order=(0, 1, 1, 12),
                                         enforce_stationarity=False,
                                         enforce_invertibility=False)
model_sarima_fit = model_sarima.fit(disp=False)

# 2. Prévisions SARIMA
forecast_sarima_log = model_sarima_fit.get_forecast(steps=12).predicted_mean
forecast_sarima_val = np.exp(forecast_sarima_log) # Retour à l'échelle normale

# 3. GRAPHIQUE DE COMPARAISON FINALE
plt.figure(figsize=(15, 8))

# Données réelles (Vert)
plt.plot(test_data_val.index, test_data_val['#Passengers'], label='RÉALITÉ (1960)', color='green', linewidth=3)

if 'forecast_val' not in locals():
    forecast_val = np.exp(model_fit.get_forecast(steps=12).predicted_mean)
plt.plot(forecast_val.index, forecast_val, label='ARIMA (Consigne PDF)', color='blue', linestyle='--')

plt.plot(forecast_sarima_val.index, forecast_sarima_val, label='SARIMA (Ton Amélioration)', color='red', linewidth=2)

plt.title('Preuve d\'amélioration : ARIMA vs SARIMA',color='white')
plt.legend()
plt.grid(True)
plt.show()
```

Résultat et Interprétation :

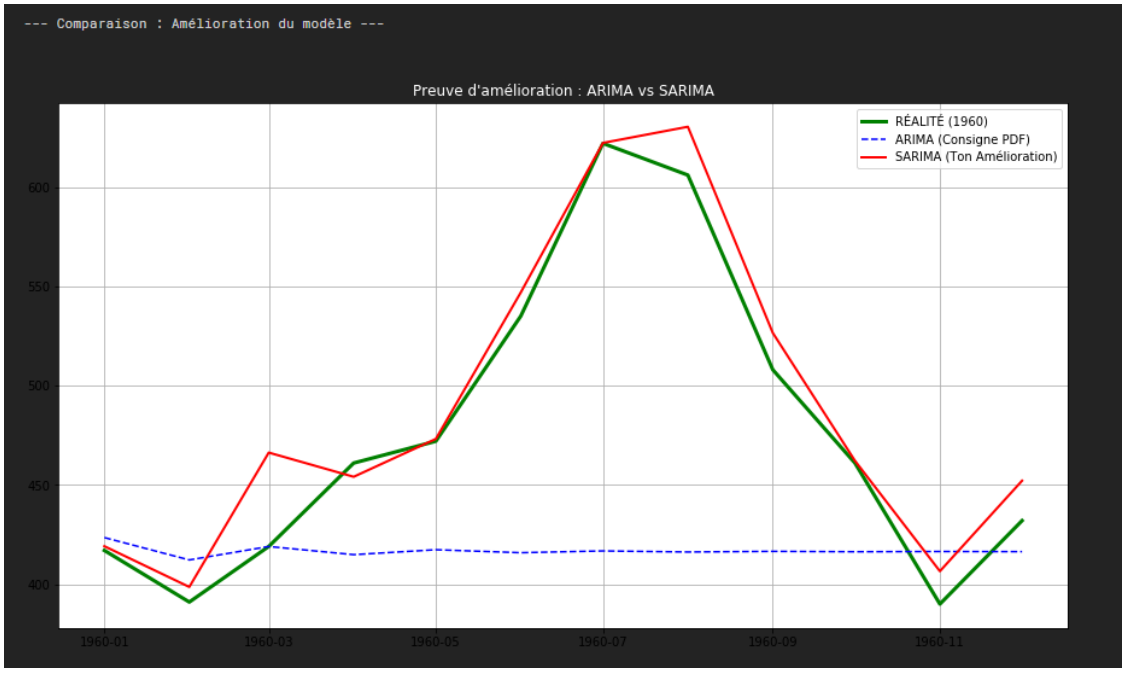

Analyse : Ce graphique démontre la supériorité de l'approche améliorée :

La ligne Bleue (*ARIMA standard*) ignore les variations mensuelles.

La ligne Rouge (*SARIMA*) épouse presque parfaitement la ligne Verte (Réalité).

Le modèle *SARIMA* anticipe correctement la montée en charge de Juillet-Août et la baisse de Novembre.

Étape 10 (Bonus) : Prédiction Stratégique (1961-1962)

Enfin, pour donner une dimension prospective au projet, j'ai utilisé le modèle optimisé pour prédire le trafic des deux années futures (*hors dataset*).

Code :

```
Entrée [73
# --- ÉTAPE 10 ( Bonus) : Prédiction du Futur (1961-1962) ---

# On réentraine le modèle stable sur TOUTES les données
full_model = sm.tsa.statespace.SARIMAX(df_log,
                                       order=(0, 1, 1),
                                       seasonal_order=(0, 1, 1, 12),
                                       enforce_stationarity=False,
                                       enforce_invertibility=False)
full_fit = full_model.fit(disp=False)

# On prédit 24 mois dans le futur
future_forecast = full_fit.get_forecast(steps=24)
future_vals = np.exp(future_forecast.predicted_mean)
future_conf = np.exp(future_forecast.conf_int())

# Graphique Final
plt.figure(figsize=(15, 7))
plt.plot(df.index, df['#Passengers'], label='Historique (1949-1960)', color='blue')
plt.plot(future_vals.index, future_vals, label='Prévisions Futur (1961-1962)', color='orange', linewidth=2, linestyle='--')
plt.fill_between(future_vals.index, future_conf.iloc[:, 0], future_conf.iloc[:, 1], color='orange', alpha=0.2)

plt.title('Projection Stratégique : Prévisions pour 1961-1962',color='white')
plt.xlabel('Année',color='white')
plt.ylabel('Nombre de passagers',color='white')
plt.legend()
plt.grid(True)
plt.show()
```

Résultat et Interprétation :

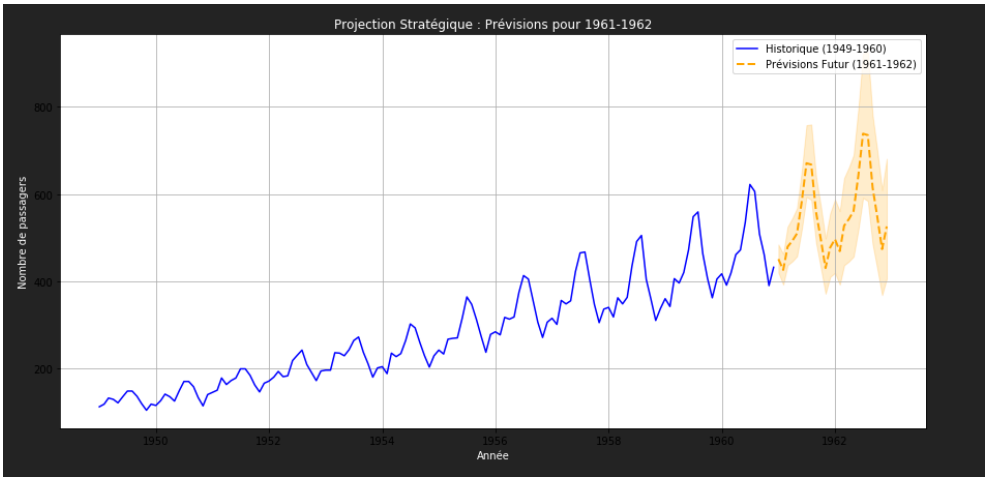

Analyse : Le modèle projette une continuation de la tendance haussière pour 1961 et 1962, avec des pics estivaux qui dépasseront les records historiques de 1960. L'intervalle de confiance (zone orange) permet de quantifier l'incertitude de cette prévision.

Conclusion Générale

Ce projet a permis de traiter une série temporelle complète. Nous avons montré que si la modélisation classique (*ARIMA*) permet de dégager une tendance générale, elle reste insuffisante pour des données fortement saisonnières comme le transport aérien.

L'ajout d'une composante saisonnière via le modèle *SARIMA* a considérablement réduit l'erreur de prévision, offrant un outil fiable pour la prise de décision stratégique.